ПИИ-2026 - ПРОЕКТНЫЙ ПРАКТИКУМ 2

СИСТЕМА МОНИТОРИНГА ДАННЫХ В БД (FLASK)

КЕЙС №5, КОМАНДА 7

Александр Новиков **(Team Lead, ML Engineer)**
Оксана Дергачева **(Team Lead, Data engineer/Backend, ML Engineer)**
Раиль Фахртдинов **(Data Analyst, ML Engineer)**
Дмитрий Шайнуров **(Data Analyst)**
Виталий Миляков **(Data engineer/Backend, ML Engineer)**
Елена Сергеева (презентатор)

СПРИНТ 1

https://github.com/aleksandr-novikov/db-monitoring

https://github.com/users/aleksandr-novikov/projects/1/views/1

ПРОБЛЕМА

В данных есть ошибки, пропуски, аномалии. Данные меняются, обновляются. Зачастую ЦА узнает об этом слишком поздно, бизнес несет убытки и теряет репутацию. Поиск проблем вручную долог и мучителен - через отдельные SQL-скрипты, разрозненные системы и Excel. Нет единого инструмента мониторинга данных в реальном времени

РЕШЕНИЕ

Инструмент мониторинга данных БД, простой и удобный, вместо тяжеловесной платформы управления инцидентами или данными. Наша главная цель — дать ЦА прозрачную картину: каким таблицам можно доверять прямо сейчас, а где есть критичные проблемы

ЦЕЛЕВАЯ АУДИТОРИЯ

- Бизнес-пользователи (Менеджеры, Руководители, BI аналитики, БА)

Формируют из БД отчеты для решения бизнес-задач

- Технические специалисты (Data/ML Engineers, админы БД)

Отвечают за актуальность, качество данных в БД

! Всем нужна уверенность в корректности и актуальности данных !

- Сфера деятельности бизнеса – любая, где накоплены данные в БД, компания понимает ценность данных и использует БД

- Стартапы, небольшие компании (нет систем мониторинга, но есть проблемы с БД)
- Компании с **legacy** (старой сложной БД, связи восстановить сложно, архитектуру менять не хочется)

ПОРТРЕТ ЦА

Анна, аналитик данных, возраст: 30 лет

Контекст работы: работает с SQL, BI-инструментами и регулярной отчётностью, готовит витрины и аналитические отчёты для бизнеса.

Основная проблема: проблемы в данных обнаруживаются уже в момент подготовки отчёта, когда время на исправление ограничено.

Ключевые сложности: позднее выявление ошибок, необходимость вручную перепроверять данные, риск построения выводов на основе некорректной информации, задержки в подготовке отчётности.

Её цель: быстро понимать, можно ли доверять данным, и сразу видеть проблемные таблицы.

Ожидание от продукта: визуальный дашборд, понятная индикация ошибок, простой интерфейс и быстрый старт без сложной настройки.

Текущие альтернативы: ручные SQL-проверки, Excel, BI-дашборды, выборочная визуальная проверка таблиц.

Триггер интереса к продукту: повторяющиеся ошибки в отчётности, необходимость регулярно перепроверять данные вручную, рост числа источников данных и таблиц.

Каналы, откуда она может узнать про наш продукт: Хабр, Telegram-каналы по аналитике и BI, профессиональные чаты аналитиков, конференции по аналитике данных, материалы по BI-инструментам.

Крик души Анны: «Мне нужен инструмент, который сразу покажет, где в данных проблема, чтобы я не искала её вручную перед сдачей отчёта».

АНАЛИЗ КОНКУРЕНТОВ - Что на рынке?

- Базы данных уже мониторят 55% компаний по всему миру (согласно исследованию New Relic «State of Observability 2024»)
- Отдельно растёт категория «data observability tools» (наблюдаемость данных), которая включает не только мониторинг БД, но и качество данных, аномалии

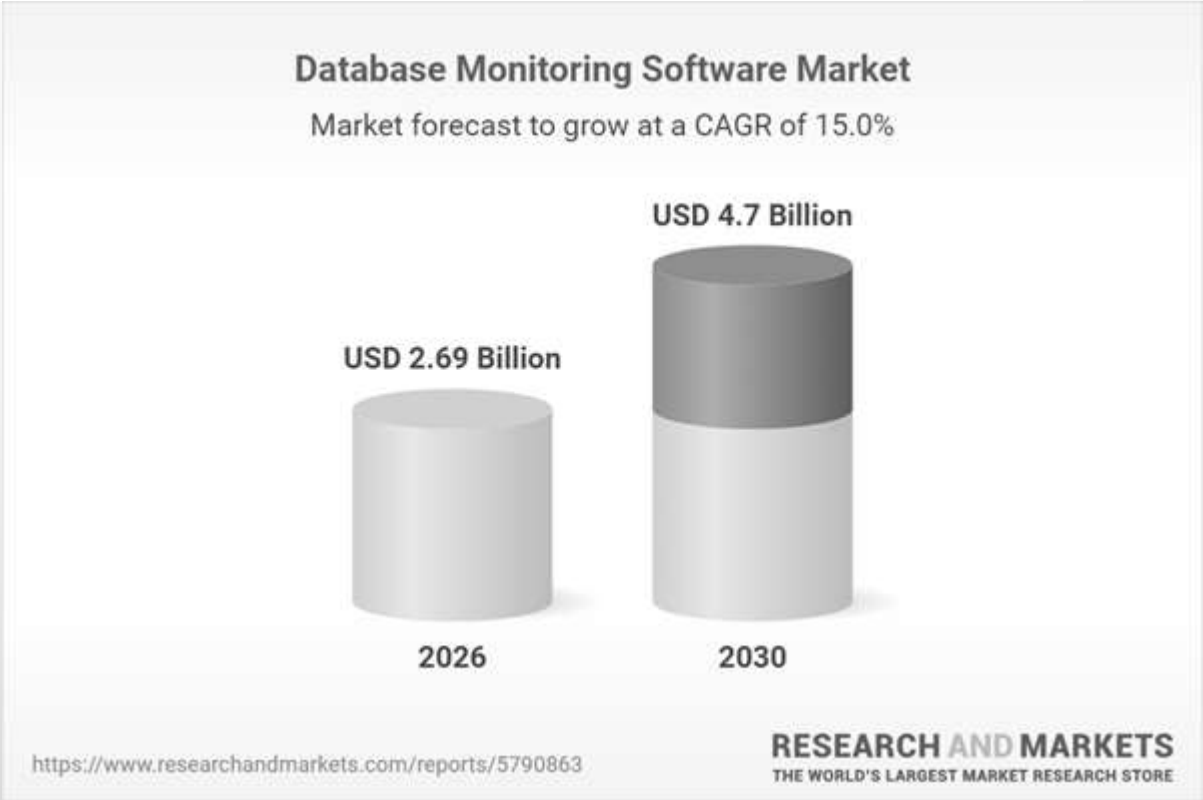

АКУЛЫ – тяжеловесные платформы за очень большие деньги - не конкурируем!

АНАЛИЗ КОНКУРЕНТОВ - Где мы?

Мощные enterprise-гиганты, например
- Monte Carlo
- Soda

МЫ

- Ручные проверки в Excel
- Кастомные скрипты

Наша уникальность — это фокус на самом востребованном сценарии без перегруженного и бюрократического функционала.
Мы предлагаем легковесный, наглядный инструмент, который можно развернуть за пару кликов, подключить базу и сразу получить минимально необходимое покрытие проверок

АНАЛИЗ КОНКУРЕНТОВ (сравнение)

Название	Описание и основные функции	Сильные стороны	Слабые функции	Уникальность	Цены / условия доступа
Great Expectations GX Cloud	управляемые правила проверки данных, контроль качества данных, облачная платформа, управление правилами и стандартами качества	сильная репутация в области контроля качества данных, гибкие проверки, бесплатный тариф для разработчиков	Больше ориентирован на технические команды; для MVP может быть избыточным	акцент на формализованных правилах проверки качества данных и управлении стандартами качества	тариф для разработчиков — бесплатно; командный и корпоративный тарифы — по запросу
Soda	контроль качества данных, мониторинг состояния данных, интеллектуальные оповещения, функции на основе искусственного интеллекта, интерфейс без программирования	понятный интерфейс, удобная совместная работа, развитая система оповещений	командный тариф уже достаточно дорогой; в большей степени ориентирован на крупные компании	сочетание контроля качества данных, удобного интерфейса и развитой системы оповещений	Free / от $500/мес / по запросу
Monte Carlo	мониторинг данных и ИИ-моделей, оповещения, отслеживание связей между данными, поддержка расследования инцидентов	зрелое корпоративное решение, сильная работа с инцидентами	сложен для небольших команд, стоимость зависит от объёма использования	сильный акцент на мониторинге данных и поддержке расследования инцидентов	$50k–200k+/год (~$4–16k/мес)
Metaplane	мониторинг данных, выявление аномалий, оповещения, тарификация по объёму использования	быстрый старт, акцент на выявлении аномалий, гибкая тарификация	итоговая стоимость зависит от объёма использования и дополнительных функций	ориентация на раннее выявление аномалий и нетипичных изменений в данных	$1–3k/мес
Anomalo	платформа контроля качества данных с акцентом на автоматизированное выявление аномалий без сложной ручной настройки	акцент на no-code и машинном обучении для мониторинга данных.	меньше гибкости для ручной настройки проверок	автоматический поиск аномалий в данных с минимальной ручной настройкой, что снижает порог внедрения для команд без глубокого DQ-экспертизы	по запросу, оценочно $40–100k/год
Datafold	инструмент для сравнения данных и контроля изменений в рамках инженерного процесса и CI/CD.	сильный фокус на data diff и проверке изменений в данных при разработке.	сильнее в проверках изменений, чем в постоянном мониторинге	специализация на контроле изменений в данных до попадания в продакшен, особенно в рамках CI/CD и data engineering-процессов	$1–3k/мес

PRICING BENCHMARK + ориентиры RU

Уровень	Конкурент / тариф	Цена (оценочно)
Конкурент	Monte Carlo (enterprise-only)	$50k–200k+/год (~$4–16k/мес)
Конкурент	Bigeye, tier-based	от ~$30k/год (~$2.5k/мес)
Конкурент	Soda Core (OSS) / Cloud / Enterprise	Free / от $500/мес / по запросу
Конкурент	Anomalo	по запросу, оценочно $40–100k/год
Конкурент	Metaplane / Datafold (SMB)	$1–3k/мес
Российский	Arenadata (Luna / Catalog)	2–5 млн ₽/год (оценочно)
Российский	VK Tech Data Platform (включая DQ)	в составе платформы, от 3 млн ₽/год
Российский	Naumen DQ (кастомные проекты)	от 5–10 млн ₽ за проект
Российский	Yandex DataLens (встроенные DQ-проверки)	бесплатно / pay-as-you-go в облаке
RU-ориентир	Free	до 5 датасетов
RU-ориентир	Team	15–30k ₽/мес (3–10 датасетов)
RU-ориентир	Business	80–150k ₽/мес (до 50 датасетов + ML)
RU-ориентир	Enterprise on-prem	2–6 млн ₽/год

КОНЦЕПЦИЯ ПРОДУКТА – функционал и ценность

- Веб-приложение на Flask, которое подключается к PostgreSQL
- Система будет собирать профиль данных и гонять проверки по заданным правилам — мы ищем NULL-ы, дубли, пустые значения. Но одних правил мало. Поэтому мы добавляем базовый ML-модуль выявления аномалий. Машинное обучение здесь не заменяет жесткие правила, а дополняет их. Оно нужно, чтобы ловить нетипичное поведение — например, резкий непредсказуемый скачок количества строк или внезапный рост пропусков, который обычной проверкой по порогу не поймать.
- **ЦЕННОСТЬ СИСТЕМЫ:**

- Убирает разрозненность проверок: ключевые сигналы качества собираются в одном интерфейсе.
- Снижает долю ручного контроля: часть проверок выполняется автоматически по расписанию или по запросу
- Ускоряет обнаружение ошибок: пользователь видит проблемные таблицы, тип проблемы и уровень критичности
- Повышает доверие к данным: у команды появляется единый источник статуса качества данных и история проверок
- Ускоряет реакцию на инциденты: видны изменения во времени, подозрительные отклонения и потенциальные аномалии

КОНЦЕПЦИЯ ПРОДУКТА – сценарии и метрики

ПОЛЬЗОВАТЕЛЬСКИЕ СЦЕНАРИИ:

1. Подключение базы данных
2. Быстрая проверка выбранных таблиц
3. Получение сигнала о возможной проблеме
4. Контроль качества данных в динамике

ИНТЕРФЕЙС:

1. Обзор
2. Таблицы
3. Схемы

ОСНОВНЫЕ МЕТРИКИ УСПЕШНОСТИ:

1. Время до обнаружения проблемы
2. Доля автоматически выявленных проблем
3. Доля ложных срабатываний
4. Сокращение времени на ручные проверки

ВСПОМОГАТЕЛЬНЫЕ МЕТРИКИ УСПЕШНОСТИ:

1. Доля критичных таблиц, покрытых проверками
2. Время выполнения проверки